






PROJET KAGGLE PRÉDICTION DU DIABÈTE

Catteau Elsa, Prouzet Charlotte & Zaari Jabri Safia



I. OBJECTIF DU PROJET

Le diabète est une maladie chronique qui affecte des millions de personnes dans le monde.

Sa détection précoce est essentielle pour prévenir les complications graves et améliorer la qualité de vie des patients.

BUSINESS GOAL

- Déterminer quels sont les facteurs de la vie quotidienne qui influencent le diabète
- Sensibiliser les risques du diabète en montrant des liens concrets dans les données

TECHNICAL GOAL

- Identifier et classer les variables les plus pertinentes pour la prédiction de diabète
- Comprendre l'impact de chaque variable sur le risque de diabète
- Sélectionner les features à retenir pour une future modélisation

II. DESCRIPTION DES DONNÉES

Dataset composé de 10 000 enregistrements et de 20 features :

- Variables numériques continues (float)
- Variables numériques discrètes (int)
- Variables catégorielles
- Variables booléennes (encodées 1=Oui et 0=Non)

Distribution de la variable cible :

```
table(df$diabetes)
```

renvoie

0	1
5044	4956

>> Les classes sont équilibrées :

- 50.4% de non diabétiques
- 49.6% de diabétiques

II. DESCRIPTION DES DONNÉES

Dataset composé de 10 000 enregistrements et de 20 features :

- **Variables numériques continues (float)**
- Variables numériques discrètes (int)
- Variables catégorielles
- Variables booléennes (encodées 1=Oui et 0=Non)

Variables numériques continues (float) :

- Bmi = Indice de masse corporelle
- Glucose = Taux de glucose sanguin (mg/dL)
- Blood_pressure = Pression artérielle (mmHg)
- Cholesterol = Taux de cholestérol (mg/dL)
- Heart_rate = Fréquence cardiaque (bpm)
- Sleep_hours = Heures de sommeil par nuit
- Steps_per_day = Nombre de pas quotidien
- work_hours = Heures de travail par jour
- Water_intake_ltr = Consommation d'eau en L
- Insulin = Niveau d'insuline (μ IU/mL)

II. DESCRIPTION DES DONNÉES

Dataset composé de 10 000 enregistrements et de 20 features :

- Variables numériques continues (float)
- **Variables numériques discrètes (int)**
- Variables catégorielles
- Variables booléennes (encodées 1=Oui et 0=Non)

Variables numériques discrètes (int) :

- Id = Identifiant unique
- Age
- Stress_level = Niveau de stress (de 1 à 10)
- diet_score = Score diététique (de 1 à 10)

II. DESCRIPTION DES DONNÉES

Dataset composé de 10 000 enregistrements et de 20 features :

- Variables numériques continues (float)
- Variables numériques discrètes (int)
- **Variables catégorielles**
- Variables booléennes (encodées 1=Oui et 0=Non)

Variables catégorielles :

- Gender (Male / Female)
- Physical_activity (Low / Medium / High)

II. DESCRIPTION DES DONNÉES

Dataset composé de 10 000 enregistrements et de 20 features :

- Variables numériques continues (float)
- Variables numériques discrètes (int)
- Variables catégorielles
- **Variables booléennes (encodées 1=Oui et 0=Non)**

Variables booléennes :

- Smoking = Fumeur
- Alcohol_intake = Consommation d'alcool
- Family_history = Antécédents familiaux de diabète
- Diabetes = Diagnostic de diabète <-> variable cible

II. DESCRIPTION DES DONNÉES


Dataset composé de 10 000 enregistrements et de 20 features :

- Variables numériques continues (float)
- Variables numériques discrètes (int)
- Variables catégorielles
- Variables booléennes (encodées 1=Oui et 0=Non)

id	age	gender	bmi	glucose	blood_pressure	cholesterol	heart_rate	sleep_hours	physical_activity	smoking	alcohol_intake	family_history	stress_level	diet_score	steps_per_day	work_hours	water_intake_lt	insulin	diabetes
1	69	Male	23.3	170	137	139	66	6.4	High	1	1	1	8	3	8760	6	3.6	33	0
2	32	Male	25.0	184	177	250	75	6.4	Medium	0	1	1	4	7	7682	11	4.1	36	0
3	89	Female	28.57	87	164	225	102	7.5	Medium	1	0	0	6	5	15025	8	1.4	46	1
4	78	Male	15.85	96	113	158	112	6.9	Low	0	1	1	2	7	4645	4	4.4	171	1
5	38	Female	35.74	171	122	193	109	7.4	Medium	0	1	0	6	9	7862	13	3.9	235	0
6	41	Male	26.24	98	107	209	60	9.9	Medium	1	0	1	2	10	4849	12	3.1	30	0
7	20	Male	17.25	98	135	257	89	8.7	Low	0	0	0	1	1	11604	8	4.7	26	0
8	39	Male	25.79	171	126	287	93	5.0	Medium	0	0	0	5	6	7398	9	4.1	96	0
9	70	Female	20.49	160	114	260	113	6.7	High	1	1	1	4	9	3735	5	3.0	21	0
10	19	Male	20.14	74	157	163	93	4.6	Medium	0	1	0	4	1	16432	13	4.5	231	0
11	47	Male	19.69	166	161	151	97	6.6	High	0	0	1	1	6	13140	13	4.5	33	0
12	55	Male	23.72	84	98	149	90	8.0	High	1	1	0	9	3	11605	7	3.5	277	0
13	19	Female	35.51	74	162	248	119	3.5	Low	0	1	0	8	10	3205	5	4.5	31	1
14	81	Male	25.46	170	176	172	115	4.0	Low	0	0	1	1	8	17464	8	3.9	218	1
15	77	Female	28.47	150	130	195	67	3.1	Low	0	1	0	5	10	9245	5	1.4	98	1
16	38	Male	29.69	183	178	163	113	5.7	Medium	1	1	0	9	7	11463	5	4.5	65	0

II. DESCRIPTION DES DONNÉES

Distribution de l'âge dans notre dataset



III. ANALYSE UNIVARIÉE

1. Résumé statistique

> summary(df)

id	age	gender	cholesterol	sleep_hours	bmi	insulin	diabetes	heart_rate
Min. : 1	Min. :18.00	Length:10000	Min. :120.0	Min. : 3.000	Min. : 7.55	Min. : 10	Min. :0.0000	Min. : 60.0
1st Qu.: 2501	1st Qu.:36.00	Class :character	1st Qu.:164.0	1st Qu.: 4.800	1st Qu.:21.63	1st Qu.: 84	1st Qu.:0.0000	1st Qu.: 75.0
Median : 5000	Median :53.00	Mode :character	Median :210.0	Median : 6.500	Median :24.93	Median :157	Median :0.0000	Median : 90.0
Mean : 5000	Mean :53.54		Mean :209.3	Mean : 6.531	Mean :24.99	Mean :156	Mean :0.4956	Mean : 89.7
3rd Qu.: 7500	3rd Qu.:72.00		3rd Qu.:255.0	3rd Qu.: 8.300	3rd Qu.:28.29	3rd Qu.:229	3rd Qu.:1.0000	3rd Qu.:104.0
Max. :10000	Max. :89.00		Max. :299.0	Max. :10.000	Max. :41.59	Max. :299	Max. :1.0000	Max. :119.0
glucose	family_history	smoking	blood_pressure	diet_score	stress_level	work_hours	water_intake_ltr	
Min. : 70	Min. :0.0000	Min. :0.0000	Min. : 80.0	Min. : 1.000	Min. : 1.00	Min. : 4.000	Min. :1.000	
1st Qu.:101	1st Qu.:0.0000	1st Qu.:0.0000	1st Qu.:104.0	1st Qu.: 3.000	1st Qu.: 3.00	1st Qu.: 6.000	1st Qu.:2.000	
Median :134	Median :0.0000	Median :0.0000	Median :129.0	Median : 6.000	Median : 5.00	Median : 8.000	Median :3.000	
Mean :134	Mean :0.4972	Mean :0.4964	Mean :129.5	Mean : 5.498	Mean : 5.48	Mean : 8.488	Mean :2.993	
3rd Qu.:167	3rd Qu.:1.0000	3rd Qu.:1.0000	3rd Qu.:155.0	3rd Qu.: 8.000	3rd Qu.: 8.00	3rd Qu.:11.000	3rd Qu.:4.000	
Max. :199	Max. :1.0000	Max. :1.0000	Max. :179.0	Max. :10.000	Max. :10.00	Max. :13.000	Max. :5.000	
alcohol_intake	physical_activity	steps_per_day						
Min. :0.0000	Length:10000	Min. : 1000						
1st Qu.:0.0000	Class :character	1st Qu.: 5688						
Median :1.0000	Mode :character	Median :10527						
Mean :0.5037		Mean :10503						
3rd Qu.:1.0000		3rd Qu.:15271						
Max. :1.0000		Max. :19999						



2. Valeurs manquantes

```
cat("Nombre de valeurs manquantes :", sum(is.na(df)), "\n")
```

>> renvoie "Nombre de valeurs manquantes : 0"

3. Données aberrantes (Outliers)

ÉTAPE 1 - On trace les boxplot relatifs à chaque variable numérique continue pour détecter visuellement les outliers




3. Données aberrantes (Outliers)

ÉTAPE 2 - On traite les outliers

1. On identifie les bornes avec la méthode IQR


```
Q1 <- quantile(df$bmi, 0.25)
Q3 <- quantile(df$bmi, 0.75)
IQR_val <- IQR(df$bmi)
borne_inf <- Q1 - 1.5 * IQR_val
borne_sup <- Q3 + 1.5 * IQR_val
```



2. On crée un nouveau tableau sans les outliers

```
df_clean <- df[df$bmi >= borne_inf & df$bmi <= borne_sup, ]
```

3. On affiche le nouveau boxplot



ÉTAPE 1 - On pose les bornes des variables à nettoyer

```
bornes <- list(  
  glucose = c(40, 300),  
  blood_pressure = c(60, 200),  
  cholesterol = c(100, 300),  
  bmi = c(15, 50),  
  age = c(18, 100),  
  heart_rate = c(40, 180),  
  sleep_hours = c(3, 12),  
  steps_per_day = c(0, 50000),  
  work_hours = c(0, 10),  
  water_intake_ltr = c(0.5, 5),  
  insulin = c(0, 50)  
)
```

ÉTAPE 2 - On cherche pour chaque variable, le nombre de valeurs qui sont en dehors des bornes

```
df_propre <- df  
for(var in names(bornes)) {  
  if(var %in% names(df)) {  
    min_val <- bornes[[var]][1]  
    max_val <- bornes[[var]][2]  
  
    hors_bornes <- sum(df[[var]] < min_val | df[[var]] > max_val, na.rm = TRUE)  
    if(hors_bornes > 0) {  
      cat(var, ":", hors_bornes, "valeurs hors bornes", min_val, "-", max_val, "\n")  
    }  
  }  
}
```








→
dans notre cas

"Bmi : 194 valeurs hors bornes 15 - 50
Insulin : 8600 valeurs hors bornes 0 - 50"

ÉTAPE 3 - On remplace les valeurs extrêmes (hors bornes) par les bornes minimales/maximales définies.


```
df_propre[[var]][df_propre[[var]] < min_val] <- min_val  
df_propre[[var]][df_propre[[var]] > max_val] <- max_val
```


5. Distribution des variables




IV. ANALYSE MULTIVARIÉE

1. Matrice de corrélation




2.Analyse du diabète par rapport aux variables numériques



les moyennes de chaque groupe :

	Diabete	age	bmi	glucose	blood_pressure	cholesterol	insulin
1	0	53.54107	24.97702	134.2574	129.4025	209.8527	156.9801
2	1	53.55285	24.97929	133.8124	129.5740	208.7929	154.9870






2.Analyse du diabète par rapport aux variables numériques




les moyennes de chaque groupe :

	Diabete	heart_rate	sleep_hours	steps_per_day	work_hours	water_intake_ltr
1	0	89.47149	6.515630	10450.55	8.473884	3.011922
2	1	89.86931	6.548313	10561.99	8.500203	2.973720


2.Analyse du diabète par rapport aux variables catégorielles et booléennes




3. Proportion de personnes diabétiques selon l'intensité de leur pratique sportive et leur genre



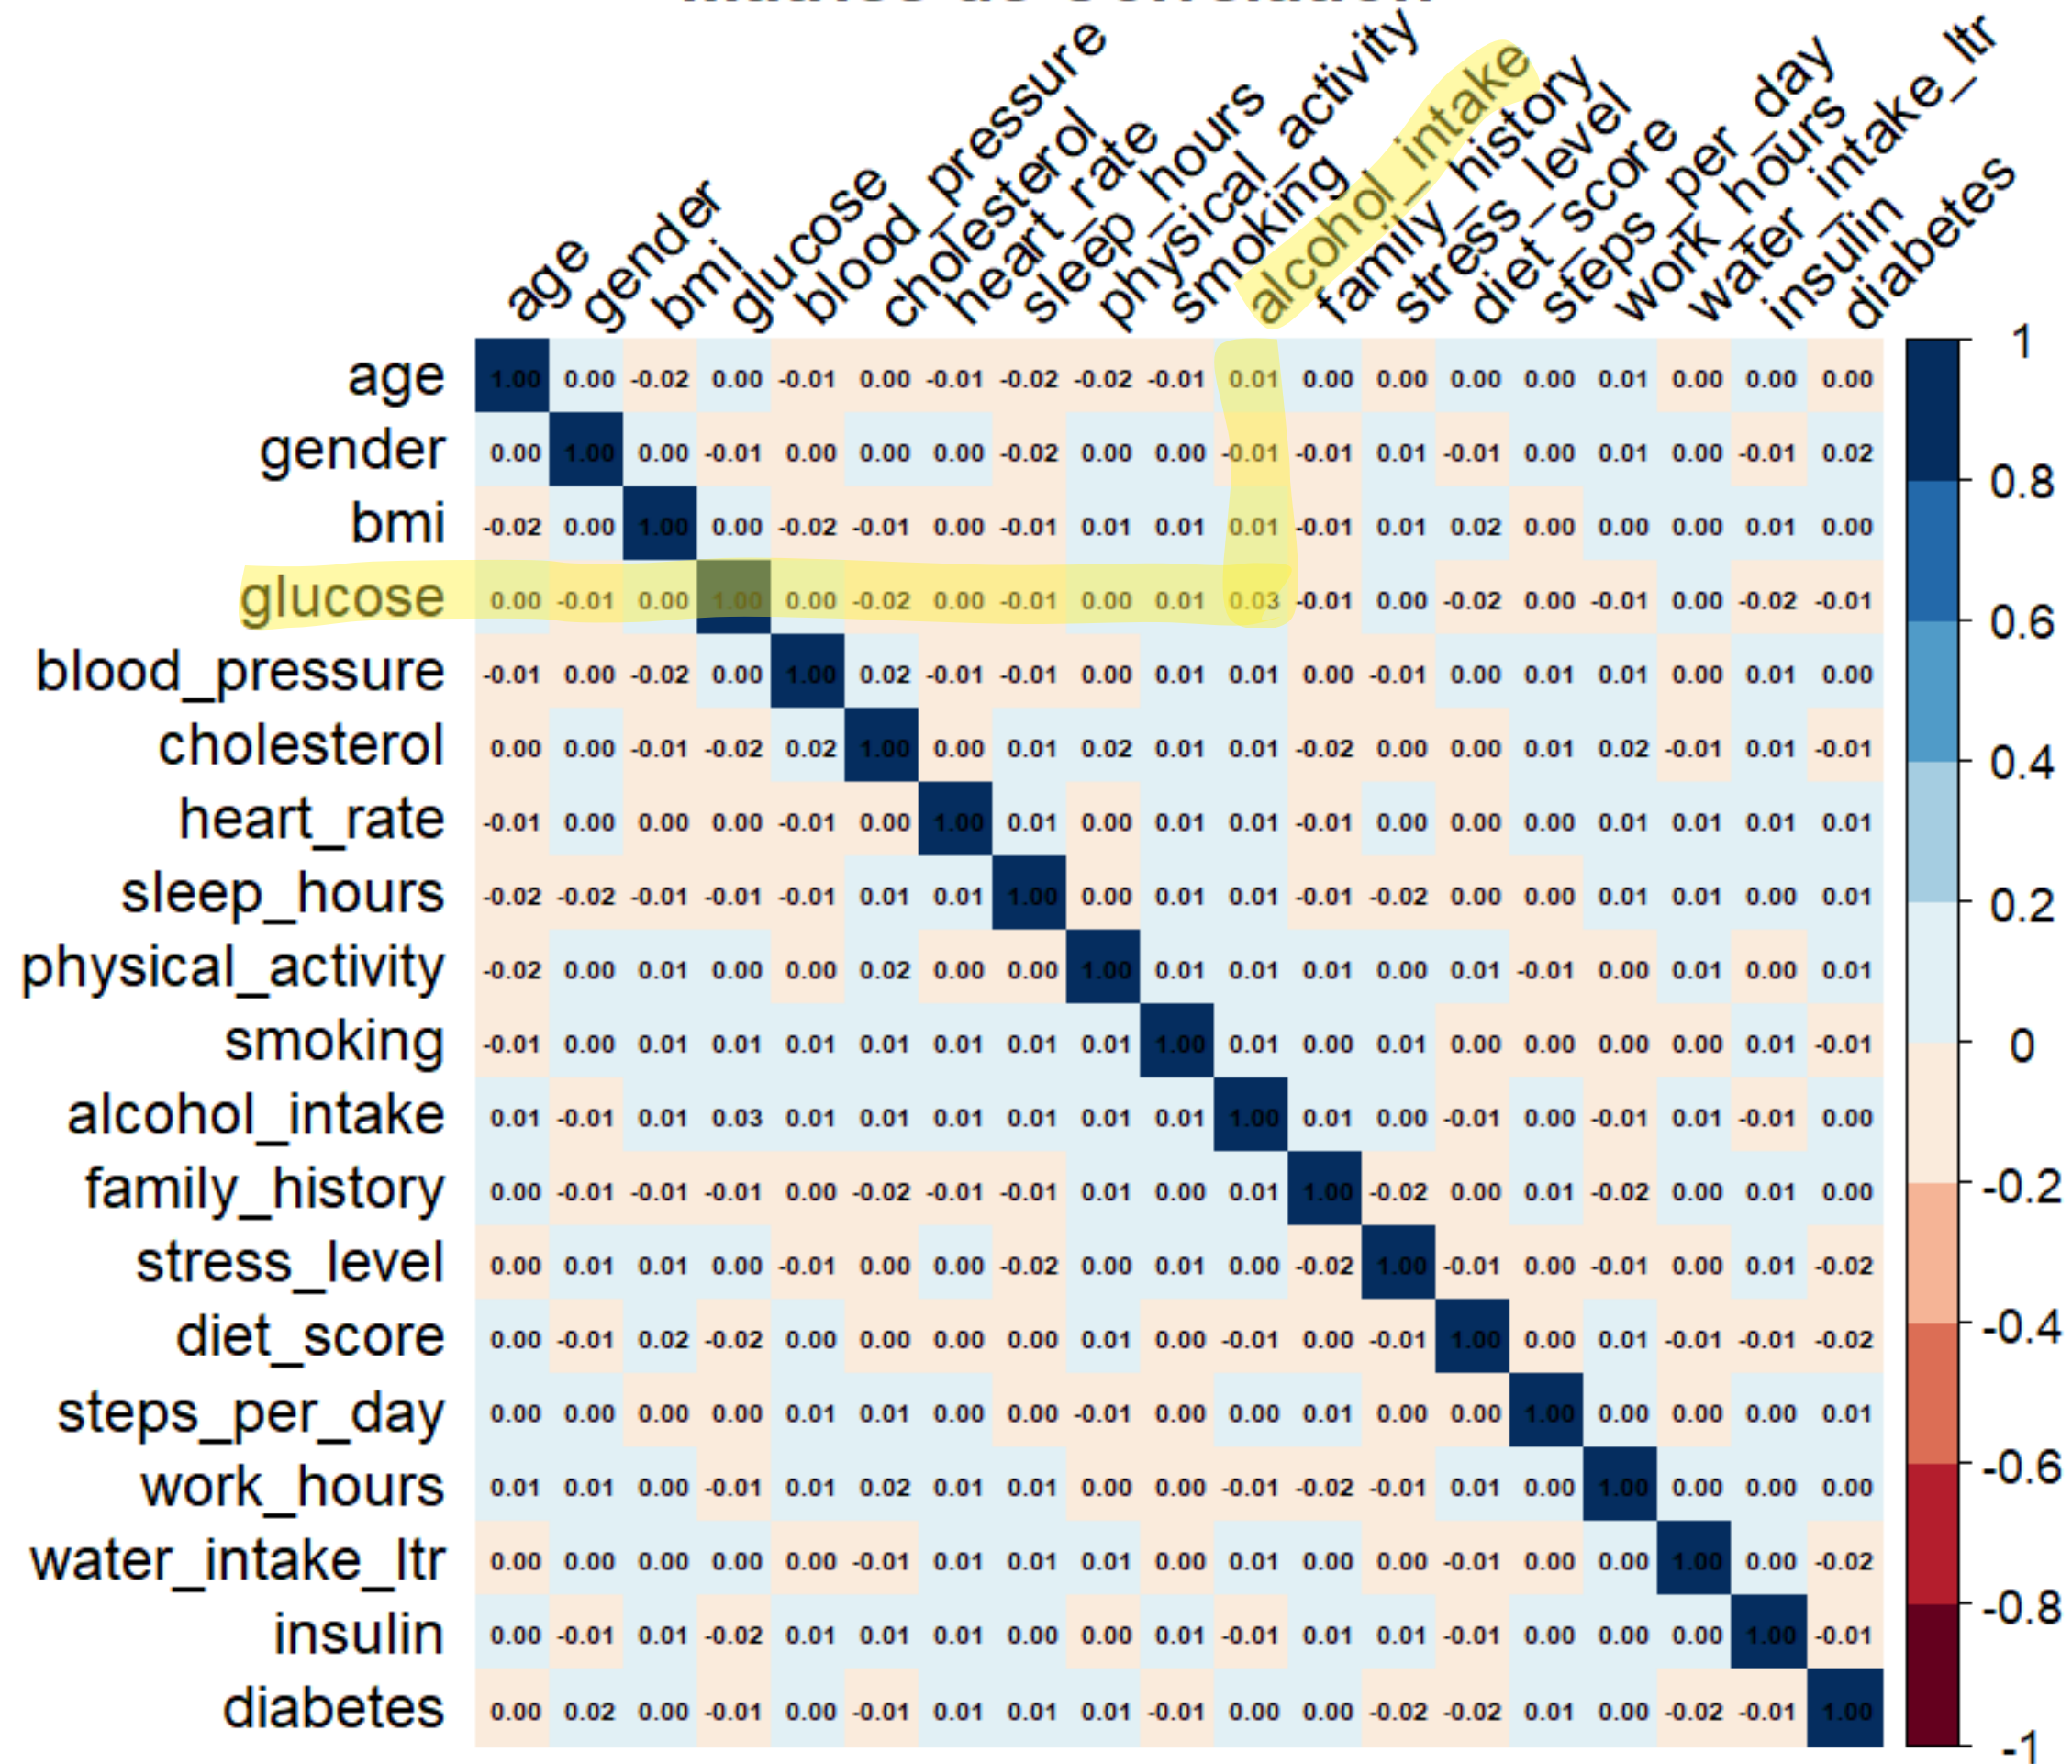
>Résultat contre-intuitif : le graphe suggère que plus la pratique sportive est intense, et plus le risque de diabète augmente.




4. Proportion de personnes diabétiques selon leur tranche d'âge et leur genre




Matrice de Corrélation



5. Proportion de personnes diabétiques selon leur niveau de glucose dans le sang et selon s'ils consomment ou non de l'alcool



6. Proportion de personnes diabétiques selon leur genre et leurs antécédents familiaux



Le diabète est plus fréquent chez les femmes ayant des personnes diabétiques dans leur entourage.

CONCLUSION

Absence de corrélation : La matrice de corrélation et les boxplots comparatifs montrent qu'aucune variable ne présente de lien linéaire avec le diabète.

Pour la suite de l'étude, nous mettrons en œuvre une régression logistique afin de déterminer si une combinaison de ces variables permet de prédire la probabilité d'être diabétique.



**MERCI POUR VOTRE
ATTENTION :)**