






PROJET KAGGLE PRÉDICTION DU DIABÈTE

Catteau Elsa, Prouzet Charlotte & Zaari Jabri Safia



I. Approche statistique avancée


Nous avons choisi de comparer 4 méthodes d'apprentissage supervisé pour la classification binaire :

- Régression Logistique
- Naive Bayes
- Random Forest
- SVM (Support Vector Machine)

Pourquoi cette approche ?

- la variable cible est binaire
- on veut comparer différentes familles d'algorithmes pour identifier le plus performant
- le SVM a été équilibré pour gérer le déséquilibre potentiel des classes

II. PCA



> Les deux groupes sont complètement mélangés.

> Il n'y a pas de cluster distinct qui isolerait naturellement les patients diabétiques.

III. Description de l'approche statistique avancée

1. Régression logistique


- Méthode de référence interprétable
- Modélise la probabilité d'appartenance à une classe via la fonction logistique:

$$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

- Les coefficients sont interprétables comme des facteurs de risque.

III. Description de l'approche statistique avancée

1. Régression logistique



III. Description de l'approche statistique avancée

2. Naive Bayes


- Méthode probabiliste simple et rapide
- Applique le théorème de Bayes avec l'hypothèse (naïve) d'indépendance conditionnelle des variables. Calcule la probabilité d'appartenance à chaque classe et choisit la plus probable.

Théorème de Bayes :

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

III. Description de l'approche statistique avancée

2. Naive Bayes



III. Description de l'approche statistique avancée


3. Random Forest

- Méthode d'ensemble basée sur des arbres de décision
- Combine plusieurs arbres de décision construits sur des échantillons bootstrap, avec un sous-ensemble aléatoire de variables à chaque nœud. La prédiction finale est obtenue par vote majoritaire.


III. Description de l'approche statistique avancée

3. Random Forest

Importance des variables - Random Forest



Courbe ROC - Random Forest




III. Description de l'approche statistique avancée

4. SVM - Support Vector Machine

- Séparation Optimale : Création d'un "hyperplan" qui maximise la distance (marge) entre les groupes.
- Vecteurs de Support : Seuls les points les plus proches de la frontière définissent le modèle.
- Astuce du Noyau (Kernel Trick) : Projette les données complexes dans un espace 3D pour les rendre linéairement séparables.

III. Description de l'approche statistique avancée

4. SVM - Support Vector Machine



IV. Mesure de performance

On a utilisé plusieurs métriques complémentaires:

- AUC (Area Under the Curve) : métrique principale qui mesure la capacité du modèle à distinguer les classes, indépendamment du seuil. Valeur entre 0.5 (aléatoire) et 1 (parfait).
- Accuracy : taux de bonnes prédictions $((VP + VN) / \text{total})$
- Matrice de confusion : visualisation des vrais positifs, vrais négatifs, faux positifs et faux négatifs
- Validation croisée (caret) 5-fold : pour évaluer la stabilité du modèle

V. Prétraitement des données

Les étapes de préparations ont été :

1. Transformation des variables catégorielles
 - physical_activity : Low→0, Medium→1, High→2
 - gender : Male→0, Female→1
2. Traitement des outliers sur la variable BMI (méthode IQR) :
 - $Q1 = 24.5$, $Q3 = 34.2$, $IQR = 9.7$
 - Bornes : [9.95, 48.75]
 - Suppression des individus hors de ces bornes
3. Création de la variable cible : transformation en facteur avec labels "Non" et "Oui"
4. Split train/test : 80% entraînement, 20% test (seed=123 pour reproductibilité)

VI. Analyse des résultats

1. Résultats comparatifs

Modele	AUC_Manuel	AUC_Caret	Difference
Régression Logistique	0.502	0.500	0.002
Naive Bayes	0.497	0.505	0.008
Random Forest	0.502	0.492	0.010
SVM	0.510	0.507	0.003

VI. Analyse des résultats

2. Matrice de confusion (pour SVM)

Référence		
Prédiction	Non	Oui
Non	532	465
Oui	551	440



Vrais négatifs : 532 patients non-diabétiques correctement prédits

Vrais positifs : 440 patients diabétiques correctement prédits

Faux positifs : 551 patients sains prédits à tort comme diabétiques

Faux négatifs : 465 patients diabétiques non détectés

VI. Analyse des résultats



Méthodes implémentés avec caret

Méthodes implémentés manuellement

VI. Analyse des résultats

Analyse de SVM avec caret :

AUC = 0.507 : très proche de 0.5 (modèle aléatoire)

Accuracy $\approx$ 50% : performance équivalente à un tirage au sort

Les 4 modèles donnent des résultats très similaires

Résultats pas bons d'un point de vue prédictif mais montrent que les variables disponibles ne permettent pas à elles seules de prédire le diabète avec certitude

VII. Conclusion

Pourquoi les performances sont-elles faibles ?

- Le diabète est une maladie multifactorielle complexe
- Trop de variables non pertinentes (sommeil, pas, eau, travail)
- Les variables disponibles ne capturent pas tous les facteurs de risque
- Il manque des données essentielles comme la glycémie à jeun, ou encore le régime alimentaire

Pistes d'amélioration concrètes :

1. Sélectionner uniquement les variables cliniques (glucose, insuline, IMC, âge)
2. Ajouter des données médicales de qualité (HbA1c...)
3. Créer des ratios pertinents (glucose/insuline)
4. Tester d'autres modèles :
 - XGBoost ou LightGBM (gradient boosting)
 - Réseaux de neurones avec plusieurs couches

The background features decorative wavy lines in orange and blue. A thick blue line starts from the top left, curves down and to the right, then up and to the right, ending near the top right. Another thick blue line starts from the bottom right, curves up and to the left, then down and to the left, ending near the bottom left. The areas between these lines and the corners are filled with orange.

**MERCI POUR VOTRE
ATTENTION :)**